# R2-A2-S8 Tarea documento: Informe de resultados de tratamiento de imagen

Julian Esteban Ballesteros Ortiz

Juan Diego Walteros Cortes

Universidad de Cundinamarca

Especialización Inteligencia Artificial

CADI Percepción Computacional - CAD2202023102

MÓNICA MARÍA FONSECA VIGOYA

martes, 13 de octubre de 2026

## Resumen

Este informe analiza cómo las condiciones de captura afectan la utilidad de imágenes para tareas de percepción computacional. Se procesaron 16 fotografías JPEG RGB de 4000 x 3000 píxeles de un convertidor de audio, agrupadas en ocho imágenes de baja iluminación y ocho de iluminación ambiente mediante un umbral de brillo de 80/255. El diagnóstico combinó brillo, contraste, proporción de sombras, entropía, estimación de alta frecuencia, varianza del Laplaciano y densidad de bordes. I01 presentó el menor brillo (44,92), la mayor proporción de sombras (45,70 %) y la menor entropía (6,79 bits). Se compararon ecualización global, CLAHE, corrección gamma y combinaciones con reducción de ruido. El flujo seleccionado aplicó Non-Local Means antes de gamma 0,56. En I01 el brillo aumentó a 85,58, las sombras bajaron a 8,49 % y la entropía subió a 7,29 bits; la estimación de ruido cayó de 1,13 a 0,58. La densidad de bordes también disminuyó, aunque quedó sobre el promedio de referencia. El tratamiento recupera información tonal, pero no reconstruye detalle perdido y evidencia un compromiso entre aclarado, suavizado y contraste local. Los encuadres distintos limitan la comparación y no se mide precisión de una CNN.


**Palabras clave:** tratamiento de imagen, OpenCV, exposición, reducción de ruido, percepción computacional.

# R2-A2-S8 Tarea documento: Informe de resultados de tratamiento de imagen

## Introducción

En percepción computacional, la imagen de entrada condiciona la información disponible para detectar, describir o clasificar objetos. Las redes convolucionales aprenden patrones visuales desde los píxeles y el preprocesamiento puede corregir degradaciones específicas, como exposición insuficiente, antes de una tarea posterior (Rodríguez Araújo, 2019; YouTube, s. f.). Sin embargo, una imagen visualmente atractiva no garantiza que conserve rasgos relevantes.

Esta práctica diagnostica fotografías del mismo objeto, selecciona una captura problemática, justifica un tratamiento con medidas y compara los resultados. Como PSNR requiere imágenes comparables y alineadas, el análisis usa métricas sin referencia y comparación descriptiva de histogramas, no una puntuación perceptual absoluta (Doumet, 2019). Los bordes responden a cambios de intensidad y pueden confundirse con textura o ruido; su densidad no equivale a calidad ni rendimiento de reconocimiento (Thipkham, 2018; OpenCV, s. f.).

## Método

### Conjunto y protocolo

Se analizaron 16 imágenes consecutivas de un convertidor digital-analógico USB S.M.S.L. Los archivos son JPEG RGB de 4000 x 3000 píxeles (12 MP), de 2,8 a 4,4 MB. El inventario detectó EXIF en las 16 capturas. La secuencia muestra varias caras y ángulos bajo distintas condiciones de iluminación; no es un diseño factorial controlado, por lo que orientación, encuadre y luz cambian simultáneamente.

El brillo medio en escala de grises dividió el grupo: baja iluminación si era menor que 80 y ambiente si era igual o superior. El umbral cae en un intervalo vacío entre los bloques del conjunto. Es descriptivo, no universal.

### Métricas

Se calcularon brillo, desviación estándar de gris, porcentaje bajo 30/255, entropía, estimación de ruido mediante la máscara de Immerkær, varianza del Laplaciano y densidad de Canny. El estimador de Immerkær puede responder a líneas y textura fina; se interpreta como indicador comparativo y no como medición pura del ruido del sensor (Immerkær, 1996). La varianza del Laplaciano también responde a detalle y ruido. Canny se aplicó tras suavizado gaussiano y umbrales automáticos; sus bordes representan discontinuidades, no contornos semánticos.

### Selección y tratamiento

I01 se seleccionó por el menor brillo medio, el mayor porcentaje de sombras y la menor entropía. Muestra la cara frontal y una zona central iluminada de forma desigual respecto del equipo y el fondo. I10 pertenece al grupo de mayor brillo, pero presenta otro ángulo; por ello se comparan métricas globales e histogramas, no PSNR o SSIM de píxel a píxel.

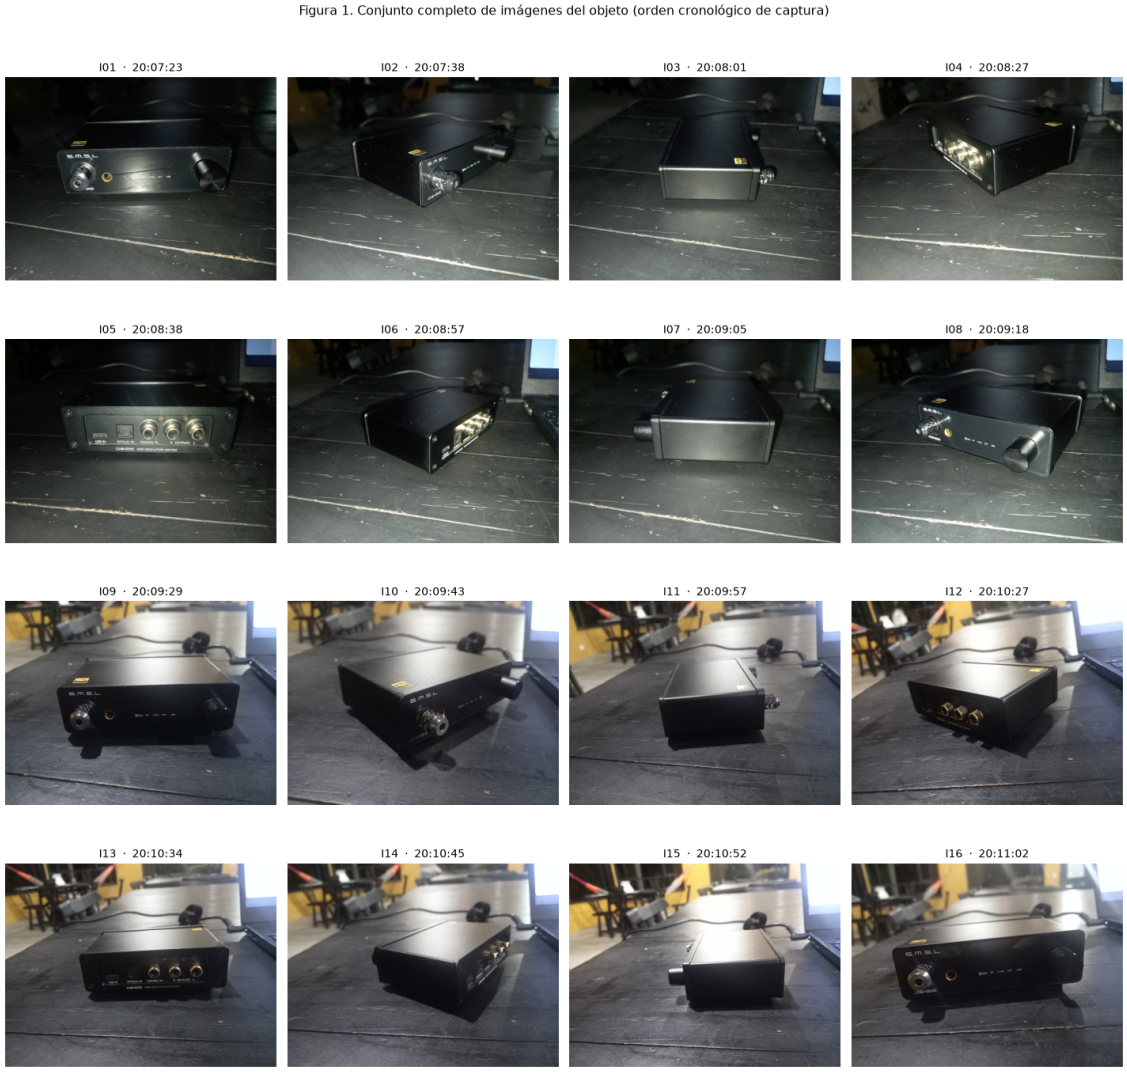
Se compararon ecualización global del canal Y, CLAHE en L, gamma aislada, Non-Local Means antes de gamma y esa secuencia con CLAHE adicional. Gamma se calculó como ln(Bobjetivo/255) / ln(Bentrada/255), usando el brillo medio de I01 y la mediana del grupo ambiente. La decisión consideró brillo, sombras, entropía, ruido estimado, bordes y distancia de histogramas.

## Resultados

### Diagnóstico del conjunto

Ocho imágenes quedaron debajo de 80 y ocho por encima. En promedio, el grupo oscuro presentó brillo 62,94, 30,17 % de píxeles en sombra y contraste 45,74. El grupo ambiente alcanzó brillo 97,78, 10,63 % de sombras y contraste 58,18. La entropía media fue 7,18 frente a 7,47 bits. La estimación de alta frecuencia fue superior en el grupo ambiente; ello advierte que el estimador responde a textura y estructura, no solo al sensor.

**Figura 1**



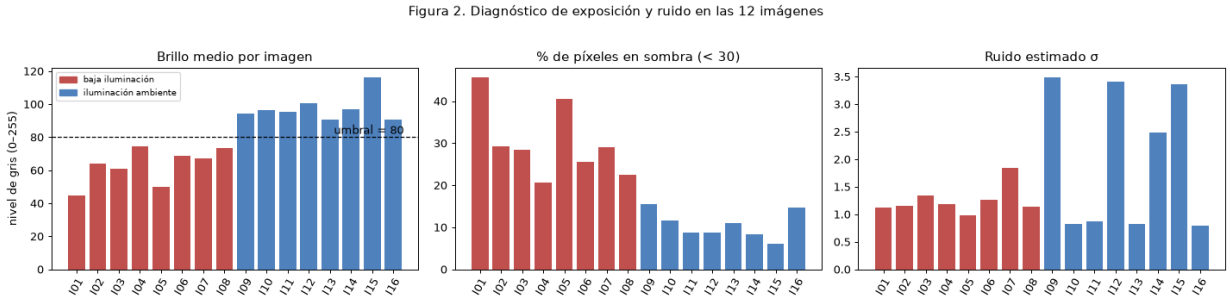

*Mosaico cronológico de 16 capturas. Las primeras ocho se clasificaron como baja iluminación y las ocho últimas como ambiente. Cambian orientación e iluminación. Fuente: ejecución del cuaderno.*

**Tabla 1**

| Condición | n | Brillo M | Contraste DE | Sombras % | Entropía | Ruido est. |
|---|---|---|---|---|---|---|
| Baja iluminación | 8 | 62,94 | 45,74 | 30,17 | 7,18 | 1,25 |
| Iluminación ambiente | 8 | 97,78 | 58,18 | 10,63 | 7,47 | 2,01 |

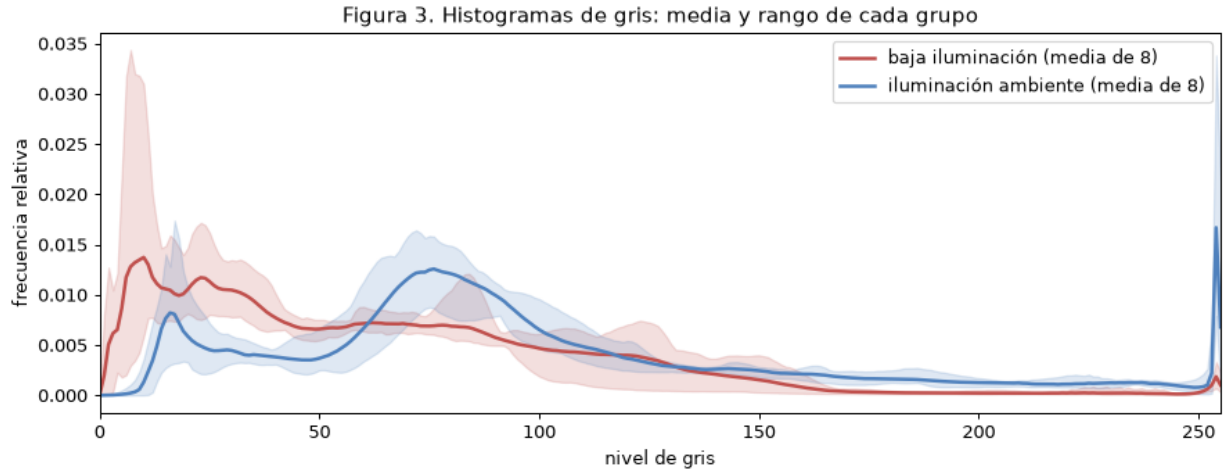
*Nota. M = media; DE = desviación estándar espacial. El ruido estimado es sensible a estructura y textura.*

**Figura 2**




*Brillo, sombras y estimación de ruido por imagen. La línea discontinua señala el umbral de agrupación.*

**Figura 3**



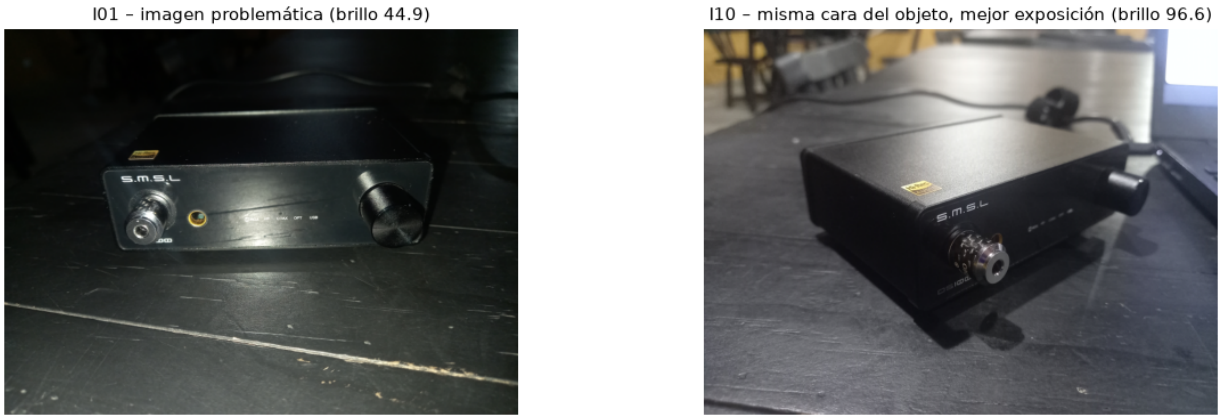

*Histogramas de gris por condición; se muestran la media del grupo y el rango entre capturas.*

## Selección de I01 y evaluación por zona

I01 tuvo brillo 44,92, 45,70 % de píxeles bajo 30/255 y entropía 6,79 bits. En la cara frontal se distinguen la perilla, un conector y la marca, pero equipo y fondo se integran en sombras. En la región frontal medida por el cuaderno, el brillo fue 77,69 y 12,52 % de píxeles quedaron en sombra; fuera de ella, el brillo fue 40,87 y casi la mitad de píxeles quedó bajo ese umbral.

**Figura 4**

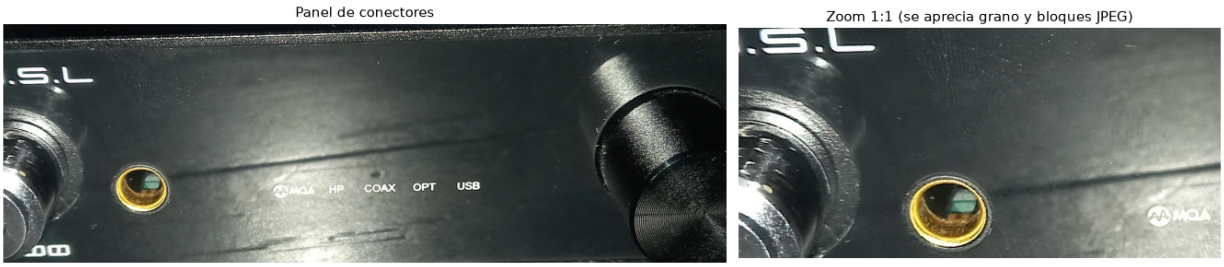
Figura 4. Imagen problemática frente a una referencia bien expuesta




*I01 e I10 como comparación ilustrativa. Los ángulos difieren; no son imágenes alineadas.*

**Figura 5**

Figura 5. I01 sin tratamiento – región de interés




*Recorte de la región frontal de I01 antes del tratamiento; la ampliación permite observar variación de alta frecuencia.*

## Comparación de tratamientos

La mediana del grupo ambiente fue 96,0 y gamma resultó 0,563. El tratamiento propuesto alcanzó brillo 85,58, 40,65 niveles por encima de I01. Las sombras bajaron 37,21 puntos porcentuales y la entropía subió 0,50 bits. El brillo quedó bajo el objetivo. En la región central, el contraste disminuyó 10,18 %; fuera de ella el brillo casi se duplicó, un costo de la transformación global.

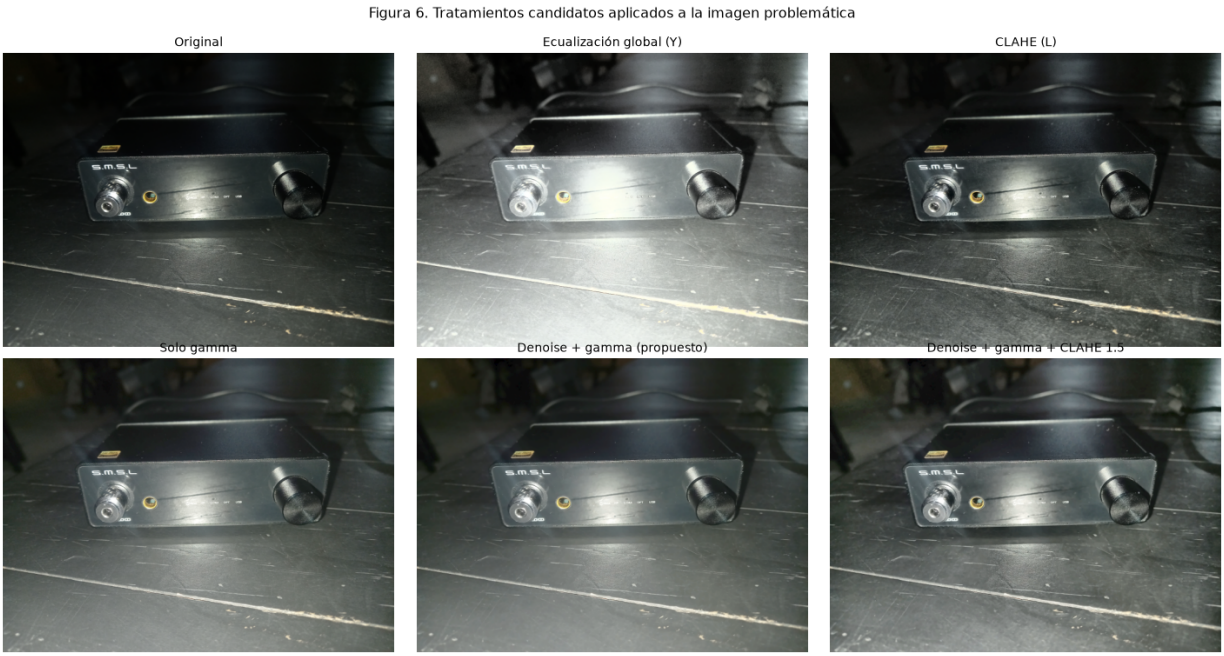
**Tabla 2**

| Alternativa | Brillo | Sombras % | Ruido est. | Entropía | Bhattacharyya |
|---|---|---|---|---|---|
| Original | 44,92 | 45,70 | 1,13 | 6,79 | 0,434 |
| Ecualización global Y | 128,99 | 9,14 | 2,22 | 6,61 | 0,669 |
| CLAHE L | 59,54 | 34,22 | 2,22 | 7,06 | 0,287 |

| Alternativa | Brillo | Sombras % | Ruido est. | Entropía | Bhattacharyya |
|---|---|---|---|---|---|
| Solo gamma | 86,43 | 6,52 | 1,38 | 7,27 | 0,287 |
| NLM + gamma | 85,58 | 8,49 | 0,58 | 7,29 | 0,287 |
| NLM + gamma + CLAHE | 89,19 | 6,39 | 0,90 | 7,37 | 0,231 |
| Referencia ambiente | 97,78 | 10,63 | 2,01 | 7,47 | - |

*Nota. NLM = Non-Local Means. Bhattacharyya compara histogramas globales; menor valor indica mayor similitud distributiva, no identidad visual. El flujo elegido es un compromiso, no maximiza todas las medidas.*

**Figura 6**



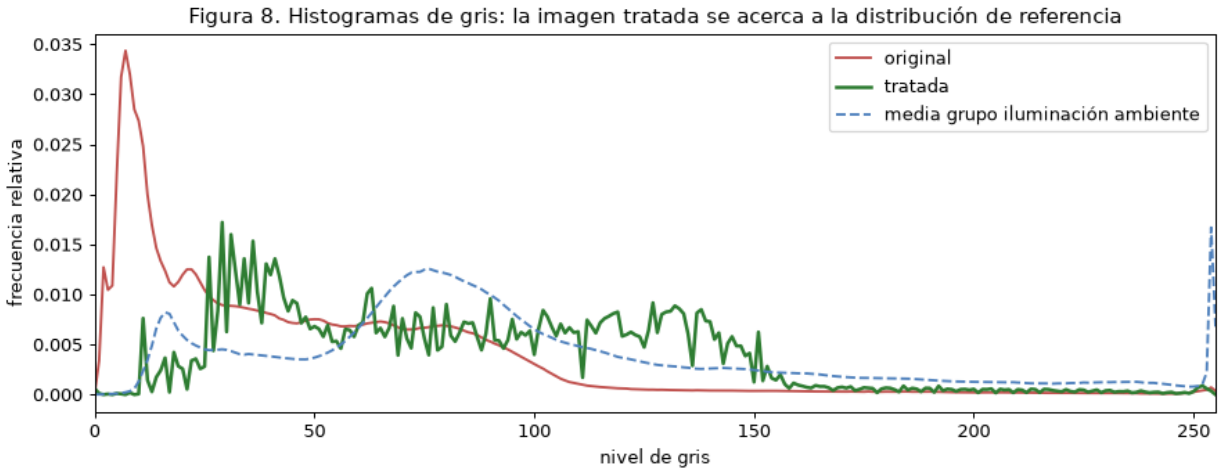

*Cinco alternativas sobre I01. La ecualización global sobreexpone; CLAHE amplifica variación local; NLM + gamma aclara con menor ruido estimado.*

**Figura 7**



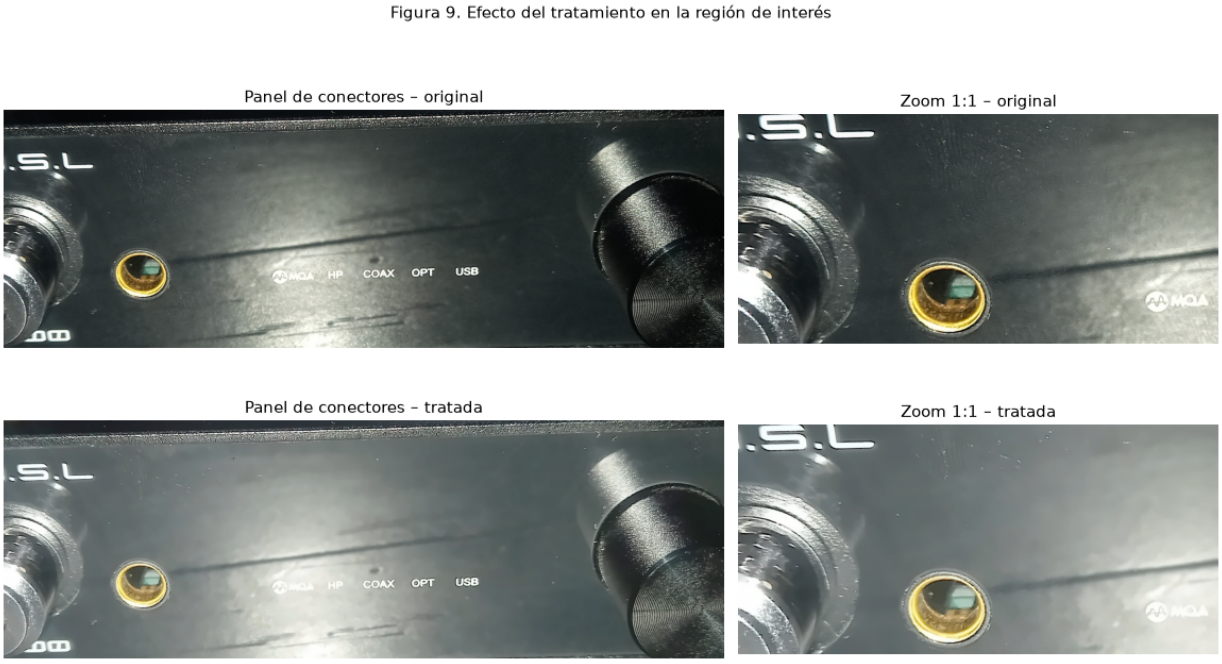

*I01 original y resultado de NLM seguido de gamma (0,56).*

**Figura 8**




*Histogramas de I01 original y tratada frente a la media del grupo ambiente.*

**Figura 9**

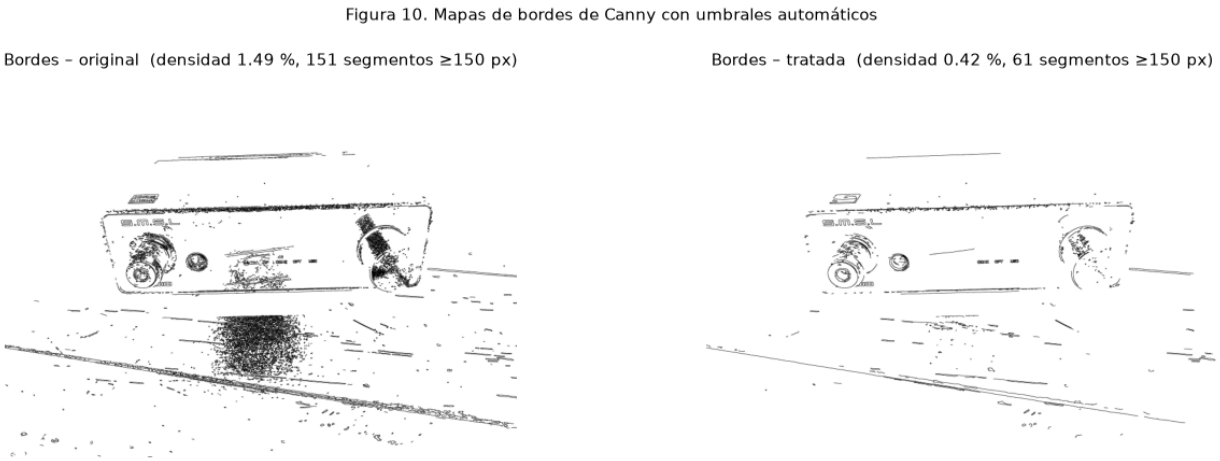



*Detalle de la región de interés antes y después. El suavizado puede borrar letras o bordes delgados.*

## Bordes y verificación del flujo

La densidad Canny de I01 pasó de 1,492 % a 0,419 %; los segmentos de al menos 150 píxeles bajaron de 151 a 61. El grupo ambiente promedió 0,255 %. La caída muestra menor respuesta de alta frecuencia, pero no demuestra recuperación de bordes semánticos: también influyen textura y encuadre.

**Figura 10**




*Mapas de Canny antes y después. Se reducen bordes detectados, incluidos los que podían corresponder a textura.*

El flujo se aplicó a las ocho imágenes oscuras con gamma individual. En promedio, el brillo pasó de 62,94 a 89,24; las sombras de 30,17 % a 9,31 %; y la entropía de 7,18 a 7,36 bits. El ruido estimado pasó de 1,25 a 0,46. El valor inferior al promedio ambiente (2,01) puede reflejar suavizado; no indica mejor calidad por sí solo.

**Figura 11**




*El mismo flujo antes/después en las ocho imágenes oscuras. Gamma se adaptó por imagen y cada par mantiene la misma vista.*

## Discusión

En este conjunto, las imágenes con menor brillo acumulan más sombras y muestran menor entropía; el tratamiento hace visibles tonos antes comprimidos en las regiones oscuras. Esto puede favorecer inspección humana y etapas clásicas de análisis, aunque no se midió rendimiento de un detector ni de una CNN.

La ecualización global modificó en exceso la distribución: brillo 128,99, ruido estimado 2,22 y distancia de histograma mayor. CLAHE aumentó respuesta de alta frecuencia

sin corregir suficientemente el brillo medio. Gamma sola dio un brillo parecido, pero retuvo mayor variación que NLM + gamma. El resultado se limita a este conjunto.

La varianza del Laplaciano no sirve aislada como medida de nitidez: ruido y textura elevan la respuesta. La caída del estimador de ruido puede reflejar limpieza o pérdida de textura. La inspección visual de la región de interés debe acompañar las estadísticas, sobre todo para leer etiquetas pequeñas.

La referencia I10 muestra otro punto de vista, por lo que PSNR/SSIM no serían apropiadas sin registro geométrico y correspondencia. Bhattacharyya compara histogramas globales, aunque imágenes con distribución similar pueden tener estructuras distintas (Doumet, 2019).

## Conclusiones

Las 16 imágenes JPEG de 12 MP se separaron en dos grupos por brillo. La baja iluminación se asocia aquí con más sombras y menor entropía, pero la variación simultánea de ángulo, superficie y luz impide atribuir causalidad exclusiva a la exposición.

I01 fue la más problemática según brillo, sombras y entropía. NLM + gamma (0,56) elevó el brillo a 85,58, redujo sombras a 8,49 % y aumentó entropía a 7,29 bits. También redujo la respuesta de bordes y alta frecuencia. El tratamiento mejora la inspección global, pero puede suavizar detalle fino y reducir contraste en zonas ya iluminadas.

Un estudio posterior debería capturar las mismas vistas con exposición controlada y comparar regiones alineadas. Se podría medir lectura de etiquetas o detección con una tarea definida. No se reporta precisión de CNN porque ningún modelo se entrenó ni evaluó.

## Reproducibilidad y repositorio

El cuaderno contiene las celdas prácticas de carga, inventario, diagnóstico, selección, tratamientos, bordes y verificación. Se ejecutó con el a.rar de 16 imágenes. El notebook busca el RAR en la ruta local entregada y conserva la alternativa de carga en Colab; las figuras y tablas provienen de esta ejecución.

Repositorio: github.com/Truder3105/R2-A2-S8-Tarea-documento-Informe-de-resultados-de-tratamiento-de-imagen.

Entorno: Python 3.12.14, OpenCV 5.0.0, NumPy 2.5.4 y pandas 3.0.1. El estudio es descriptivo; no se realizó análisis inferencial ni se evaluó una aplicación desplegable.

## Referencias

Doumet, F. (2019, 14 de julio). How to measure image quality? *Compression.ai.* https://compression.ai/how-to-measure-the-quality-of-an-image/

Immerkær, J. (1996). Fast noise variance estimation. *Computer Vision and Image Understanding, 64*(2), 300-302. https://doi.org/10.1006/cviu.1996.0060

OpenCV. (s. f.). *Contours: Getting started.* OpenCV Documentation. https://docs.opencv.org/5.0/py_tutorials/py_imgproc/py_contours/py_contours_begin/py_contours_begin.html

Rodríguez Araújo, J. (2019, 20 de noviembre). Cómo empezar con reconocimiento de imagen y redes neuronales convolucionales en 5 minutos. *Planeta Chatbot.* https://planetachatbot.com/como-empezar-con-reconocimiento-de-imagen-y-redes-neuronales-convolucionales-en-5-minutos/

Thipkham, P. (2018, 25 de diciembre). Image processing class #5: Edge and contour. *TDS Archive.* https://medium.com/data-science/image-processing-class-egbe443-5-edge-and-contour-d5d410f4483c

Universidad de Cundinamarca, curso de Percepción Computacional. (2026). *Guía tratamiento de imagen* [Material de curso].

YouTube. (s. f.). *Convolutional neural networks explained (CNN visualized)* [Video]. https://www.youtube.com/watch?v=pj9-rr1wDhM